阿里巴巴创新研究计划 2026

研究课题申请书

课题名称	面向 AIOps 故障应急响应的 MCP 端点专家模型自动化生产方法研究 ——基于大模型冷启动知识蒸馏
申请课题	课题一（大小模型协同）/ 课题十（AIOps 故障应急）
申请日期	2026 年 3 月
申请单位	【填写：*所在高校/科研院所全称*】
申请人（PI）	【填写：*PI 姓名*】
联系邮箱	【填写：*pi@university.edu.cn*】

本申请书响应阿里巴巴创新研究计划 *2026* 征题提交。
申请经费：人民币 *60* 万元，项目周期：一年。

1、项目简介

1.1 课题名称

面向 AIOps 故障应急响应的 MCP 端点专家模型自动化生产方法研究——基于大模型冷启动知识蒸馏

1.2 研究背景与意义

产业需求背景。阿里巴巴等大规模互联网平台运营着复杂异构的基础设施，对系统稳定性要求极高。AIOps 故障应急响应是核心运维能力，却高度依赖人工：值班工程师需在严苛时限内完成告警诊断、跨子系统日志关联与处置决策。Qwen3 系列模型 [Alibaba Cloud, 2025] 的成熟为该流程的自动化提供了现实条件。然而，云端大语言模型（LLM）单次 API 调用延迟达 500 ms–2 s，故障风暴期间甚至直接超时；而本地部署的小语言模型（SLM）推理延迟可控制在 <100 ms，在对延迟极度敏感的 AIOps 执行层具有不可替代的价值。

LLM–SLM 协同研究中被忽视的前提假设。本计划课题一聚焦于大小模型的高效协同机制。现有协同框架（如 FrugalGPT、RouteLLM）均隐含一个前提：*领域专家小模型已经存在*，其贡献在于设计高效的路由或调度策略。然而，这些工作均未回答更本质的问题：*领域专家小模型从何而来？*

链式推理训练是构建高能力 SLM 的成熟路径。STaR [Zelikman et al., 2022]、Distilling Step-by-Step [Hsieh et al., 2023] 及相关工作 [Gu et al., 2024, Dong et al., 2024, Agarwal et al., 2024] 已充分证明：在训练时为 SLM 提供*思维链*（*CoT*）推理，而非仅记忆输入输出对，能大幅提升其在领域任务上的表现。然而，获取高质量 CoT 标注需要昂贵的人工标注或具备领域先验的大型教师模型——而在*冷启动*场景下（即全新业务子领域启动时），上述两类资源均不具备。

研究空白。如图 1 所示，现有 SLM 生产方法均至少依赖以下之一：(a) 人工标注的 CoT；(b) 具有领域先验的教师模型；或 (c) 已有一定能力的学生模型作为引导。在冷启动场景——恰恰是 AIOps 新子场景上线时的普遍条件——上述前提均不成立。这一空白促成本课题的核心提案：*一套仅从原始〈输入，输出〉数据对出发*，无需人工介入、无需领域感知教师模型的 CoT 标注与 SLM 蒸馏自动化流水线。

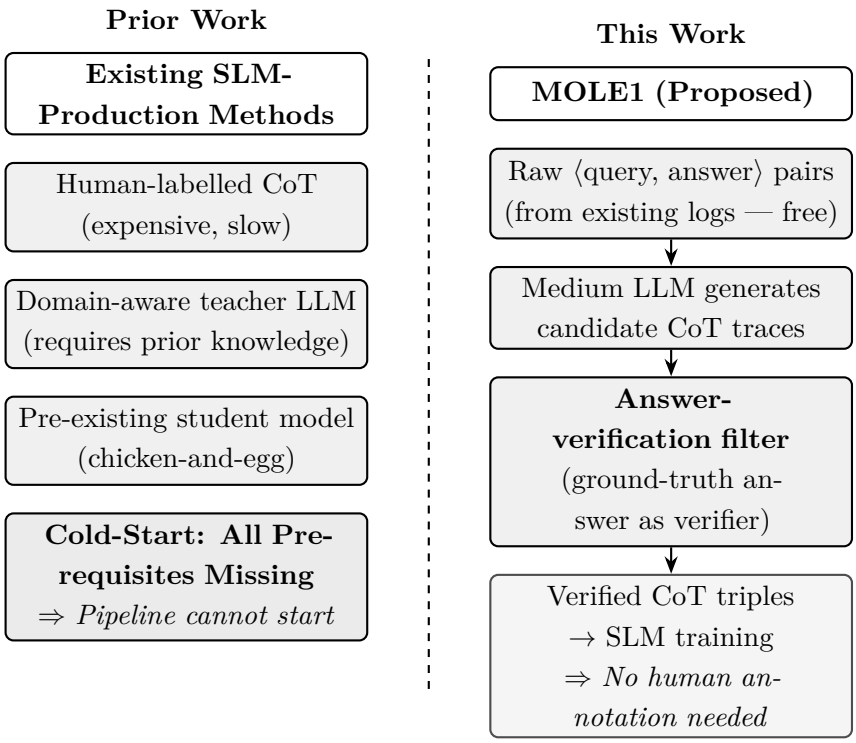

图 1: 现有 SLM 生产方法在冷启动场景下的失效（左）；MOLE1 利用已知答案作为自动验证器实现突破（右）。

为何 AIOps 是最佳验证场景。AIOps 具备三项结构性优势，使其成为验证本方法最理想的领域。

1. **数据丰富、无需标注**。大规模平台的运维数据库天然积累了海量⟨告警+日志, 处置操作⟩数据对——正是 MOLE1 所需的⟨输入, 输出⟩格式，无需额外标注成本。
2. **客观、可自动化的验证信号**。”所提处置方案是否解决了故障？”是历史记录中直接可查的真值信号，支持通过故障回放进行全自动离线评测，无需动用线上环境。
3. **延迟优势可量化**。故障响应对延迟极为敏感：本地 SLM 响应 <100 ms，云端 LLM API 调用耗时 500 ms–2 s，峰值故障风暴期间甚至超时。这 10–20 倍的延迟差距是 MOLE1 直接解决的、可量化的产业痛点。
4. **同时覆盖双课题**。本方法同时响应课题一（大小模型协同机制）与课题十（AIOps 故障应急响应），以一套方法论同时解决两个产业痛点。

1.3 研究目标

本课题设立五项紧密耦合的研究目标：

O1. MOLE1 流水线设计与实现。设计并实现完整的冷启动 CoT 自动生成与 SLM 蒸馏流水线，包括答案验证过滤机制。

O2. AIOps 场景验证。在真实或近真实的 AIOps 数据集上验证流水线，证明 MOLE1 产出的领域专家 SLM 在故障诊断与处置基准上达到或超越通用 LLM 的表现。

O3. MCP 封装与集成。将每个训练好的 SLM 封装为符合 Model Context Protocol

（MCP）标准的工具端点，实现与云端 LLM 规划层的即插即用集成。

O4. 专精化机制分析。通过严格的实证与理论分析，解释为何领域专注 SLM 能在目标任务上超越通用 LLM（”专精胜泛化”现象）。

O5. 跨领域迁移验证。将 MOLE1 流水线应用于至少一个 AIOps 以外的领域（如代码审查分类或客服意图识别），验证方法的领域无关性，证明其通用价值。

1.4 研究方法

核心思路：MOLE1——答案验证驱动的 CoT 合成

我们提出 **MOLE1**（**M**odel-**O**utput-**L**abel-**E**licited CoT Synthesis，第一版），一套**领域无关**的自动化流水线，能从原始 ⟨ 输入, 输出 ⟩ 数据对出发合成 CoT 标注训练数据，无需任何人工标注或领域感知教师模型。核心创新在于将已知答案用作自动验证器：

$$\underbrace{\langle q,\, a\rangle}_{\text{冷启动数据}} \xrightarrow{\text{中等 LLM, } k \text{ 次采样}} \text{候选 CoT} \xrightarrow{\text{答案一致性过滤}} \underbrace{\langle q,\, \text{CoT}^*,\, a\rangle}_{\text{验证数据三元组}} \xrightarrow{\text{SFT+LoRA}} \underbrace{\text{专家 SLM}}_{\text{MCP 端点}}$$

其中 q = 查询，a = 真值答案，CoT^* = 通过验证的推理链。

中等规模模型（如 Qwen3-7B）对每条查询通过温度采样（τ=0.8）生成 k 条候选推理链，仅保留最终结论与真值答案一致的推理链——这一筛选标准不依赖任何领域知识，在冷启动条件下完全可行。筛选得到的三元组用于对轻量 SLM（如 Qwen3-1.5B/3B）进行专项微调。

领域无关性说明。尽管本课题以 AIOps 作为验证领域，MOLE1 流水线完全领域无关：仅要求（i）存在历史 ⟨ 输入, 输出 ⟩ 数据对，且（ii）答案正确性可自动验证。这一条件在广泛的工业场景中均成立——客服工单分类、代码审查、供应链异常检测等——使 MOLE1 成为大小模型协同框架下通用的冷启动生产引擎，远超其 AIOps 实例化的范围。

四阶段流水线

图 2 展示了 MOLE1 的完整流水线。

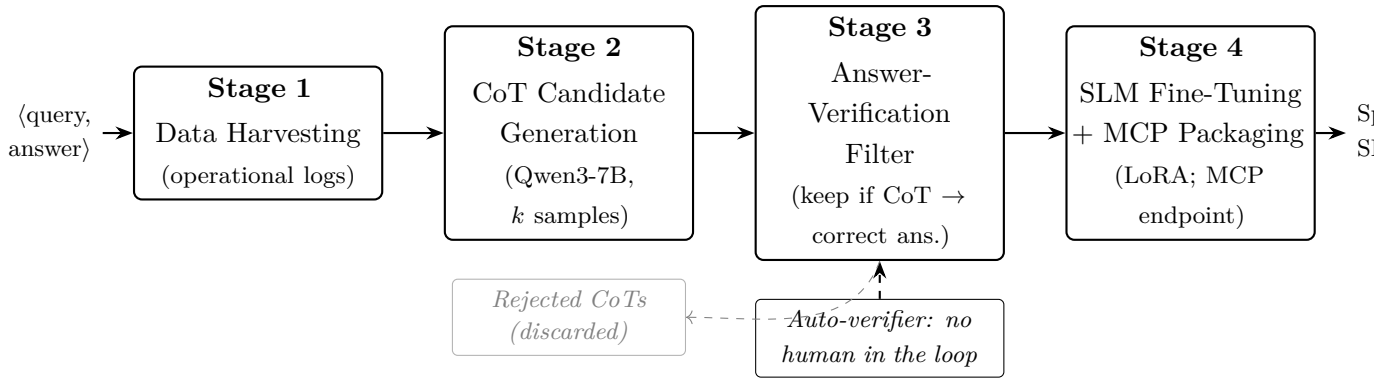

图 2: MOLE1 冷启动 SLM 自动生产四阶段流水线。

阶段一——数据采集。从运维系统采集 ⟨ 告警+日志, 处置操作 ⟩ 数据对，无需人工标注；数据来自现有的故障管理系统。同时运行轻量级异常过滤器，剔除操作员误操作或处置结果存疑的记录，确保数据质量。

阶段二——CoT 候选生成。对每条查询, Qwen3-7B 以温度采样(τ=0.8, top-p=0.95)生成 k 条候选推理链。该步骤对生成模型无领域知识要求。

阶段三——答案验证过滤。逐条评估候选 CoT 的最终结论是否与历史处置操作一致；一致者保留，不一致者丢弃。类似筛选在 STaR [Zelikman et al., 2022] 中的保留率约为 30–70%。

阶段四——SLM 微调与 MCP 封装。以验证数据三元组通过 SFT + LoRA 对轻量 SLM 进行微调；训练完成后将模型封装为 MCP 标准工具端点，注册至规划层。

实验设计与评估方案

数据集。采用两类数据：(a) 阿里巴巴运维日志内部数据集（数据使用须经双方协商的数据共享协议授权)；(b) 公开的 AIOps-2022 基准数据集 [Notaro et al., 2021]（用于可复现性对比)。实验覆盖三类 AIOps 子场景：数据库层故障、网络分区故障、容器资源耗尽。另设跨领域迁移实验（目标 O5)，在公开代码审查数据集上验证 MOLE1 的领域泛化能力。

基准对比方案。

- **仅大模型（LLM-only)**：Qwen3-72B 云端 API，无本地 SLM。
- **无 CoT 的 SLM（SLM w/o CoT)**：仅在输入输出对上微调，无推理链。
- **教师 CoT 的 SLM（SLM + teacher CoT)**：以 Qwen3-72B 生成的 CoT 微调（需要大模型教师，为" 上限" 基准)。
- **MOLE1（本文方法)**：以 Qwen3-7B 生成的答案验证 CoT 微调。

评估指标。处置动作准确率（Top-1 匹配率)、推理延迟（p50/p99)、单次查询计算成本（FLOPs / API token 数)。统计显著性通过自助法重采样验证（n=1000)。

系统架构：规划层 + MCP 工具层

图 3 展示了整体部署架构。

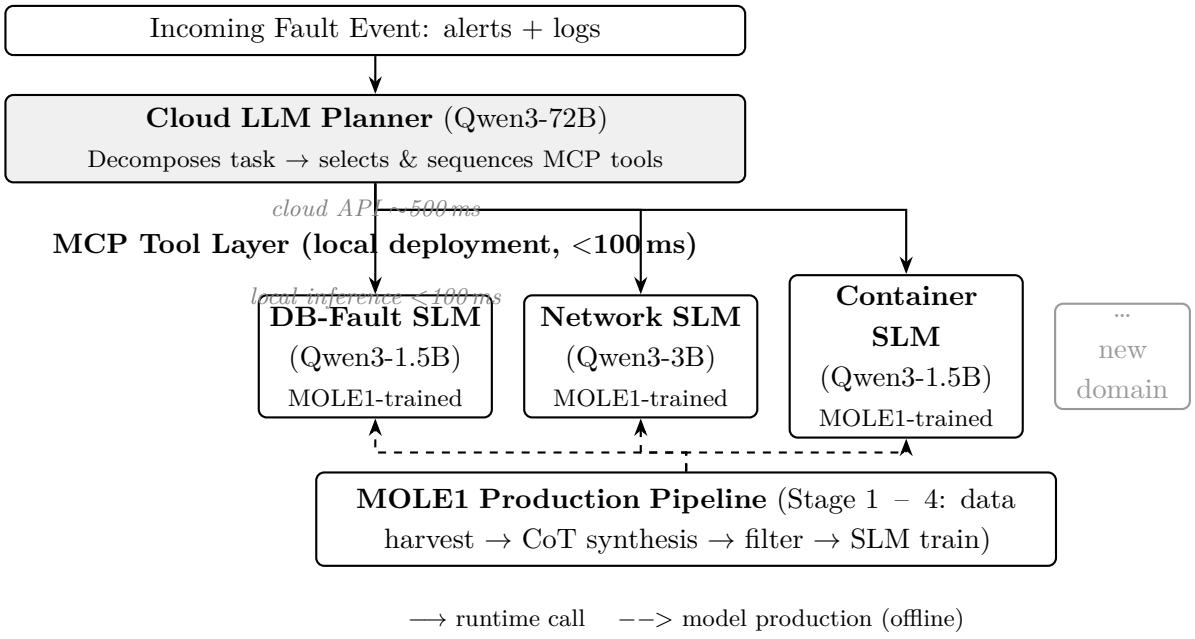

图 3: 系统架构：云端 LLM 作为规划器，调度由 MOLE1 流水线生产的 MCP 端点专家 SLM。

云端 LLM（Qwen3-72B 或同等级模型）担任**规划器**：将入站故障事件分解为子任务，确定执行顺序，并依次调用对应的 MCP 工具端点。每个 MCP 工具封装一个专项 SLM，该 SLM 经 MOLE1 在单一 AIOps 子场景（如数据库慢查询诊断、网络分区检测、容器 OOM 定位）上专项训练。

规划器 – 执行器分层设计反映了两类角色的非对称性：

- 规划器需要全局语义理解以分解复杂多步故障事件——这需要大模型的广度。
- 每个执行器需要单一子领域的深度专精——这受益于领域专项 CoT 训练，而不受益于大模型多任务训练所强制执行的泛化约束。

该设计同时带来延迟优势：仅规划器调用经过云端 API（∼500 ms）；所有执行器 SLM 推理均在本地完成（<100 ms），即便在高频告警场景下系统整体响应仍维持在秒级以内。

为何领域专精 SLM 能超越通用 LLM

”专精胜泛化”现象已得到蒸馏文献的充分支持 [Hsieh et al., 2023, Dong et al., 2024]，其原因在于：(i) 通用 LLM 的参数被数千个任务共享，导致单领域的表示容量被稀释 [Wang et al., 2025]；(ii) 在领域专项 CoT 数据上微调的 SLM 在参数空间中占据更低维的子空间，与目标领域的推理模式高度对齐，以更少的参数实现更高

的精度。本课题将提供消融实验（变量：模型规模、训练数据领域纯度）与容量分配分析，对上述直觉进行形式化论证。

为何不直接以 7B 模型作为执行器？或许有人会问：既然 Qwen3-7B 已具备 CoT 能力且可在本地单张 A10 卡上运行，为何还要进一步蒸馏为 1.5B/3B 模型？原因有三：（1）*准确率*：在领域验证 CoT 上训练的 1.5B SLM 在目标子任务上超越 7B 通用模型——领域纯度效应在此规模下主导尺寸效应 [Dong et al., 2024]；（2）*部署规模*：大型平台拥有数百台主机，1.5B SLM 可与各服务节点共部署，内存开销极低，无需 GPU 调度即可实现零延迟本地推理；（3）*成本*：1.5B 推理的 FLOPs 约为 7B 的 $\frac{1}{5}$，对于每分钟数千次故障告警的高频监控场景至关重要。

2、项目里程碑

2.1 项目周期

一年，自双方签署研究合作协议生效之日起计。

2.2 阶段计划

表 1: 项目各阶段任务与交付物

阶段	主要工作	交付物	时间
M1	**流水线设计与数据准备**。形式化 MOLE1 算法；采集并预处理 AIOps 数据集；实现 CoT 候选生成（Qwen3-7B）与答案验证过滤器。	数据集及过滤模块；技术报告。	第 1–3 月
M2	**SLM 训练与基准测试**。在验证数据三元组上微调 SLM；与通用 LLM 基准进行对比实验；专精化机制分析。	训练好的 SLM 模型；实验报告；CCF-A 论文#1 初稿。	第 4–7 月
M3	**MCP 封装与系统集成**。将 SLM 封装为 MCP 工具端点；集成规划器（Qwen3-72B）与 MCP 工具层；端到端延迟与准确率评测。	开源 MCP 工具包；系统演示；CCF-A 论文#2 初稿。	第 8–9 月
M4	**综合评测、专利申报与最终交付**。全系统评测；与阿里巴巴相关团队开展用户研究；专利申请；提交最终项目报告。	最终报告；已发表/投递论文；专利申请（1–2 项）。	第 10–12 月

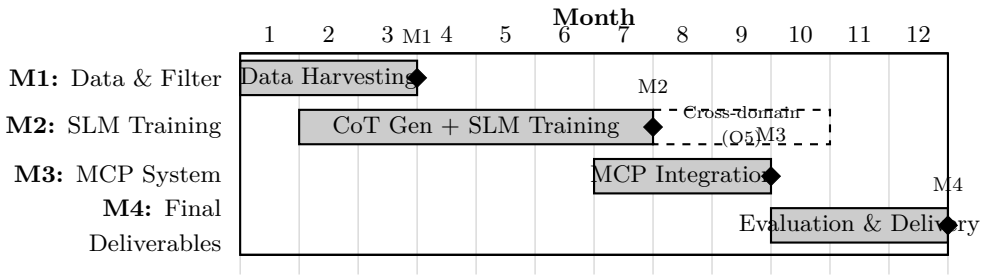

图 4: 项目甘特图（四个里程碑）。

3、预期成果

本课题承诺交付以下最终成果。

成果描述	交付形式	备注
MOLE1 冷启动 SLM 生产流水线原型系统	源代码（开源）	可复现；发布于 GitHub
符合 MCP 协议的 AIOps 工具端点工具包	源代码 + 文档	兼容 MCP 标准协议
2–3 篇 MOLE1 方法论与 AIOps 评测学术论文	学术论文	目标 CCF-A 或同级别顶会（如 NeurIPS、ICML、ACL、ICSE、FSE）
1–2 项冷启动 CoT 合成与 MCP 封装发明专利	专利申请	国际或国内发明专利
项目阶段报告（启动、中期、结题）	项目报告	按约定时间提交

预期技术指标： MOLE1 产出的 SLM 在 AIOps 故障诊断基准上准确率与 GPT-4 级 LLM 相差在 5% 以内，单次推理延迟降低 >10 倍（从 ∼1 s 降至 <100 ms），推理成本降至零（本地推理，无 API 费用）。

对阿里巴巴的预期业务价值： 一套可复用、领域无关的通用流水线，阿里 SRE 团队可在数天内将其应用于任意新 AIOps 子场景，无需标注预算，无需预置专家模型。

4、人员、设备与经费预算

4.1 项目人员

姓名	单位及职称	月劳务费（元）	参与时长	小计（元）	角色	阿里巴巴实习计划
【*PI 姓名*】	【职称】，【院校名称】	12,000	3 个月	36,000	PI	—
【博士生 *1* 姓名】	博士研究生，【院校名称】	12,000	12 个月	144,000	科研助理	第 4–6 月
【博士生 *2* 姓名】	博士研究生，【院校名称】	12,000	12 个月	144,000	科研助理	第 7–9 月
		人员费用小计（甲）				**324,000 元**

实习时间为预估安排，具体以阿里巴巴 *SRE* 团队日程为准。

4.2 设备与科研经费

经费项目	单价（元）	合计（元）	说明
GPU 云算力（A100 节点 · 时）	—	91,000	SLM 训练（阶段二至三）
本地推理服务器（租用/购置）	50,000	50,000	MCP 端点部署及延迟测试
学术会议差旅（2 次）	15,000	30,000	国内外顶会出席及汇报
开放获取论文版面费	10,000	20,000	ACL Anthology / NeurIPS 开放版面
	科研经费小计（乙）	**191,000**	

4.3 经费汇总

经费类别	说明	金额（元）
（甲）人员费用	见 4.1 节	324,000
（乙）科研经费	见 4.2 节	191,000
（丙）间接费用	学校管理费：16.5%×（甲+乙）= 16.5% × 515,000 ≈ 85,000	85,000
合计	（甲）+（乙）+（丙）	**600,000**

5、申请人简介

【*PI* 姓名】
【职称/职务】，【院系名称】，【院校名称】
邮箱：【邮箱地址】 个人主页：【主页 *URL*】

研究方向：大语言模型、知识蒸馏、AIOps、智能软件系统

代表性论文（近五年）：

1. 【作者，论文题目，期刊/会议，年份】
2. 【作者，论文题目，期刊/会议，年份】
3. 【作者，论文题目，期刊/会议，年份】

主持/参与科研项目：

- 【资助来源，项目名称，经费，起止年份】
- 【资助来源，项目名称，经费，起止年份】

与业界合作经历：【填写与阿里/工业界相关的合作经历，如有】

6、参考文献

6、参考文献

R. Agarwal, N. Vieillard, P. Stanczyk, S. Ramos, M. Geist, and O. Bachem. On-policy distillation of language models: Learning from self-generated mistakes. In *International Conference on Learning Representations (ICLR)*, 2024.

Alibaba Cloud. Qwen3 technical report. Technical report, Alibaba Group, 2025.

J. Dong et al. DDK: Distilling domain knowledge for efficient large language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.

Y. Gu, L. Dong, F. Wei, and M. Huang. MiniLLM: Knowledge distillation of large language models. In *International Conference on Learning Representations (ICLR)*, 2024.

C.-Y. Hsieh, C.-L. Li, C.-K. Yeh, H. Nakhost, Y. Fujii, A. Ratner, R. Krishna, C.-Y. Chen, and T. Pfister. Distilling step-by-step! outperforming larger language models with less training data and smaller model sizes. In *Findings of the Association for Computational Linguistics (ACL)*, 2023.

A. Notaro, J. Cardoso, M. Gerndt, and M. Brenner. Aiops: Real-world challenges and research innovations. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 12(6), 2021.

C.-Y. Wang et al. A survey of small language models. *arXiv preprint arXiv:2410.20011*, 2025.

E. Zelikman, Y. Wu, J. Mu, and N. D. Goodman. STaR: Bootstrapping reasoning with reasoning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.