阿里巴巴 AI 研究资助计划 2026

研究申请书

项目名称	基于大模型冷启动蒸馏的 MCP 端点专家模型自动化生产 ——面向 AIOps 故障应急响应
课题方向	课题一（大小模型协同）/ 课题十（AIOps）
日期	2026 年 3 月
申请机构	香港城市大学 计算机科学系
申请人（负责人）	王茂林（Maolin Wang）
电子邮件	maolwang2@cityu.edu.hk

本申请书响应 *Alibaba AI Research Scheme 2026* 资助计划。
资助金额：人民币 *60* 万元，项目周期：一年。

1. 项目介绍

1.1 项目标题

基于大模型冷启动蒸馏的 MCP 端点专家模型自动化生产——面向 AIOps 故障应急响应

1.2 背景与意义

产业背景。阿里巴巴等大规模互联网平台运维着复杂异构的基础设施，须保障近乎零停机时间。以电商大促场景为例，单次高峰期可触发数万条告警，人工 triage 每条平均耗时 5–15 分钟，[1] 由此产生数百工程师-小时的应急处置成本，且人工误判率在高压情境下显著上升。故障应急响应（AIOps）是关键运维能力，但目前仍高度依赖人工：值班工程师须在严峻时间压力下诊断告警、跨数十子系统关联日志并给出修复方案。Qwen3 系列模型 [Alibaba Cloud, 2025] 及 LLM（大语言模型）的整体成熟，为该流程的自动化打开了大门。然而，单次云端 LLM API 调用延迟高达 500 ms–2 s，在大规模故障风暴下（每分钟数千事件）甚至会超时失败；而本地部署的 SLM（小语言模型）响应时延 <100 ms，对延迟敏感的 AIOps 执行层不可或缺。

LLM–SLM 协同研究中的隐含前提。课题一要求探索大小模型如何有效协同。现有协同框架（如 FrugalGPT、RouteLLM）隐含假设 *专家小模型已经存在*：其贡献在于高效的路由或调度策略，决定由哪个模型处理某次查询。然而，这些工作并未回答更根本的问题：*专家小模型从何而来？*

推理链训练是构建高能力 SLM 的成熟路径。另一研究方向——STaR [Zelikman et al., 2022]、Distilling Step-by-Step [Hsieh et al., 2023] 及相关方法 [Gu et al., 2024, Dong et al., 2024, Agarwal et al., 2024]——已充分证明：在训练时为 SLM 引入*思维链*（*CoT*）*推理*，而非仅记忆输入输出对，能显著提升其在领域特定任务上的性能。瓶颈在于数据：获取高质量 CoT 标注，需要昂贵的人工标注员或能按需生成推理链的大型教师模型。在*冷启动*场景下——即团队进入无标注数据、无现成专家模型的新业务领域时——上述资源均不可得。

研究空白。如图 1 所示，现有 SLM 生产方法均依赖以下至少一项：(a) 人工标注 CoT；(b) 具备领域知识的教师模型；(c) 可用于引导的已有学生模型。而在冷启动场景——恰恰是新 AIOps 子场景的常态——上述前提均不成立。需要指出的是，现有 AIOps 方法（基于规则引擎、ML 分类器或检索增强生成）虽能处理 *模式匹配*类故障，却不产出可本地部署的推理型 SLM：规则引擎无法泛化到新故障类型；ML 分类器缺乏可解释的推理步骤；RAG 每次仍须调用云端 LLM，未能解决延迟问题。这一空白激发了本项目的核心提案：一套*仅从原始*〈*输入*, *输出*〉对自动生成 CoT 标注训练数据的流水线，无需任何人工介入，也无需具备领域知识的教师模型。

现有问题与困难。

(1) 冷启动场景下专家 SLM 生产" 无自动化路径"。现有 LLM–SLM 协同框架将专家小模型视为已知前提：FrugalGPT、RouteLLM 等工作贡献路由或调度策略，但不提供 Executor 本身的生产方法。实践中，新 AIOps 子场景（如新引入的服务网格或新型微服务故障类型）初始时既无标注数据，也无预训练领域模型。若缺乏从零自动化生产专家 SLM 的手段，整个协同技术栈将无 Executor 可路由。如何构建一套完全自动化、无需标注的 SLM 生产流水线，仅从原始运维记录出发，是第一项核心挑战。

(2) 工业领域的答案验证 CoT 合成" 仍未解决"。基于 CoT 的蒸馏方法——STaR [Zelikman

[1] 基于阿里巴巴内部大促运维报告估算；类似规模见 Notaro et al. [2021]。

et al., 2022]、Distilling Step-by-Step [Hsieh et al., 2023]——已充分证明推理链训练相比标准输入输出微调能产出更强的 SLM。然而，生成经验证的 CoT 标注，需要判断每条推理链是否导向正确答案，这又依赖人工评估者或领域专家教师模型。冷启动时两者均不存在。如何仅凭历史记录中已有的标准答案，在无任何领域特定监督的情况下自动验证候选推理链，且能泛化到工业 AIOps 各子场景，是第二项核心挑战。

本项目通过 MOLE1 流水线同时攻克上述两个问题，以阿里巴巴 AIOps 运营数据作为主要验证环境。

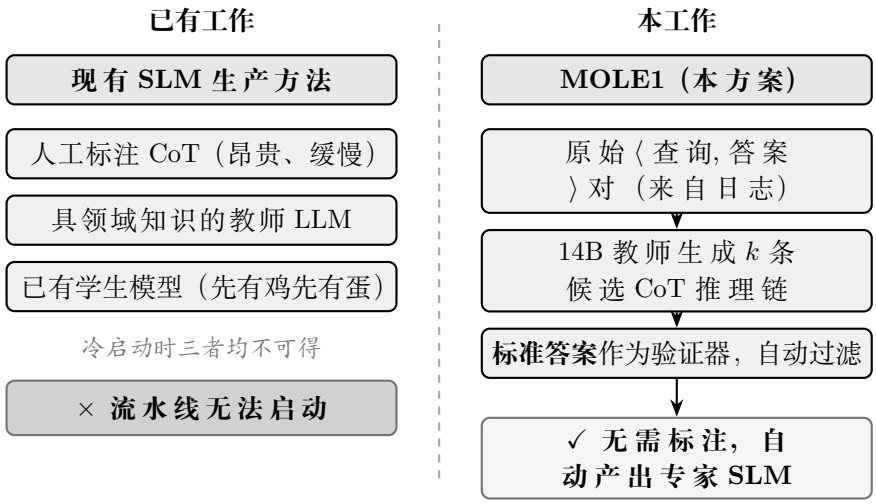

图 1: 现有 SLM 生产方法在冷启动场景下失效（左）；MOLE1 以观测答案作为自动验证器，突破这一瓶颈（右）。

为何 AIOps 是理想验证场景。三项结构性特点使 AIOps 成为验证本方案的最佳领域。

1. **数据丰富，无标注成本**。每个大规模平台的运维数据库中均积累了大量⟨告警 + 日志, 修复操作⟩对——恰好符合 MOLE1 所需的⟨输入, 输出⟩格式——无需额外标注工作量。
2. **客观二值验证**。”所提修复方案是否解决了故障？”这一真值信号已存于历史记录，可通过故障回放实现完全自动化的离线评估，无需线上环境。
3. **可量化的延迟优势**。故障响应对延迟极为敏感。本地部署 SLM 响应时延 <100 ms；云端 LLM API 调用耗时 500 ms–2 s, 峰值故障风暴时更会超时。10–20× 的延迟差距是 MOLE1 直接解决的具体工业痛点。
4. **战略双覆盖**。本方案同时直接面向课题一（LLM–SLM 协同机制）与课题十（故障应急响应 AIOps），展示了一套方法论能同时解决两大工业痛点的可能性。

1.3 研究目标

本项目设定五项紧密关联的研究目标：

O1. LLM–SLM 协同机制：冷启动 SLM 自动生产（MOLE1）。设计并实现三循环迭代流水线，解决”专家 SLM 从何而来”这一 LLM–SLM 协同框架中被忽视的前提问题：Cycle 1 答案验证 CoT 合成 + Cycle 2 SFT 监督训练 + Cycle 3 领域聚焦 GRPO + Bootstrap 自举回路，实现冷启动场景下专家 SLM 的全自动化生产。

O2. AIOps 验证。在真实或接近真实的 AIOps 数据集上验证流水线，证明 MOLE1 生产

的领域专家 SLM 在故障诊断与修复基准上能达到或超越通用 LLM 的性能。

O3. 专业化机制分析。通过以下两类分析对"专业化优于泛化"现象进行严谨的实证论证：(i) 消融实验，系统控制变量为模型规模（1.5B / 4B / 14B）、训练数据领域纯度（纯领域 vs. 混合通用数据）及 CoT 过滤率（0% / 30% / 70%）；(ii) 表示空间分析，采用 t-SNE 可视化对比专域 SLM 与通用 LLM 的激活聚类，并以层间激活相似度（CKA）量化各层特征表示的专业化程度。

O4. 跨域通用性验证（探索性）。在项目资源允许的条件下，将流水线应用于一个 AIOps 以外的公开数据集（如代码审查分类），以初步验证 MOLE1 的领域无关性；若时间有限，此目标将以消融实验形式完成并作为后续工作的铺垫。

工程交付物（非研究目标）： 将训练好的 SLM 封装为 MCP（Model Context Protocol）合规工具端点，注册至 Planner 层，实现与现有云端 LLM 基础设施的即插即用集成。MCP 封装本质上是标准化的工具调用接口工程，不构成独立研究贡献，但作为将 MOLE1 研究成果部署至生产系统的必要工程出口而包含于项目交付物中。

量化目标： MOLE1 生产的 SLM 应在 AIOps 故障诊断基准上达到 GPT-4 级 LLM 修复操作准确率的 5% 以内，将单次推理延迟降低 >10×（从 ∼1 s 降至 <100 ms），并将单查询 token 成本降至零（本地推理）。学术产出：投稿论文 2 篇至 CCF-A 或同等顶级会议（如 NeurIPS、ICML、ICSE、FSE），争取于项目结题前至少 1 篇完成录用；就冷启动 CoT 合成与 MCP 端点封装申请发明专利 1–2 项；系统在 2 个以上 AIOps 子场景完成原型部署与性能验证。

1.4 研究方法

核心思路：MOLE1——三循环迭代 CoT 合成

本文提出 **MOLE1**（**M**odel-**O**utput-**L**abel-**E**licited CoT Synthesis，第一迭代），一套领域无关的迭代流水线，能无需任何人工标注或具备领域知识的教师模型，将原始〈输入，输出〉对转化为具有推理能力的专家 SLM。系统由三个相互依存的训练循环构成，并配有一个自举（Bootstrap）回路：

$$
\begin{array}{lll}
\text{Cycle 1:} & \underbrace{\langle q, a\rangle}_{\text{冷启动数据}} \xrightarrow{\text{14B, } k \text{ 采样 + 答案过滤}} & \underbrace{\mathcal{D}^*}_{\text{验证三元组集}} \\
\text{Cycle 2:} & \mathcal{D}^* \xrightarrow{\text{SFT+LoRA}} & \underbrace{\pi_0}_{\text{初始 SLM（AIOps-0）}} \\
\text{Cycle 3:} & \pi_0 \xrightarrow{\text{AIOps-GRPO}} & \underbrace{\pi^*}_{\text{专家 SLM}} \\
\text{Bootstrap:} & \pi_t(\mathcal{D}_\emptyset) \xrightarrow{\text{过滤}} \mathcal{D}^*_{\text{new}} \hookrightarrow \mathcal{D}^* \xrightarrow{\text{触发下一轮 Cycle 1}} & \pi_{t+1}
\end{array}
$$

其中 q = 查询，a = 标准答案，CoT^* = 经验证的推理链，$\mathcal{D}_\emptyset$ = 本轮过滤率为零的失败样本集，π_t = 第 t 轮训练所得 SLM。Cycle 1 由任务可行的最小外部教师模型驱动；Cycle 3 仅使用已有的答案匹配信号作为奖励，无需引入外部监督；Bootstrap 回路则以当前 SLM 自身（而非教师模型）对失败样本重新采样，所有过滤通过的新三元组写回 $\mathcal{D}^*$ 并触发下一迭代，实现数据集与模型能力的协同进化。

领域通用性。尽管我们以 AIOps 作为验证场景，该流水线完全领域无关：仅要求 (i) 存在历史〈输入, 输出〉对，且 (ii) 答案正确性可自动验证。该条件在工业界广泛成立——客服工单分流、代码审查分类、供应链异常检测——使 MOLE1 成为 LLM–SLM 协同的通用冷启动引擎，远不止于 AIOps 场景。选择 AIOps 领域作为主要验证场景，是因为它唯一性地同时满足上述三项结构性优势，并提供了清晰、可复现的实验协议。

三循环迭代训练系统

图 2 展示了完整的 MOLE1 流水线。

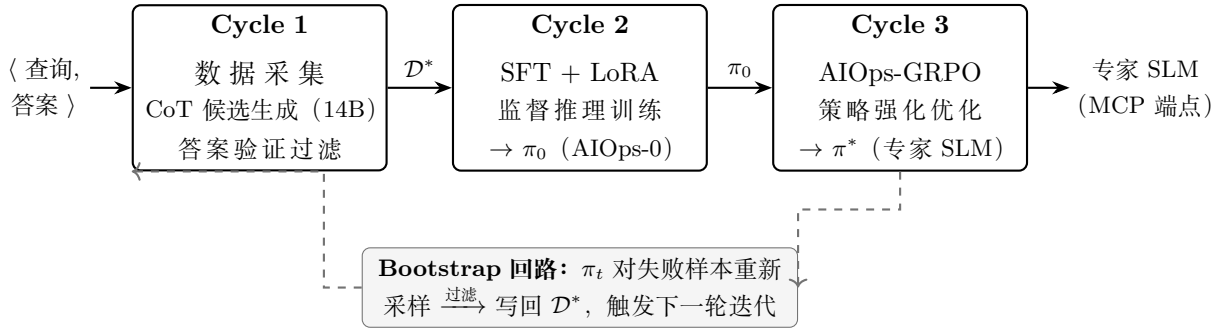

图 2: MOLE1 三循环迭代流水线：Cycle 1 产出验证数据集，Cycle 2 SFT 得到初始 SLM，Cycle 3 AIOps-GRPO 强化推理质量，Bootstrap 回路驱动协同进化。

Cycle 1——数据采集与验证 CoT 合成。 从运维日志中收集〈告警 + 日志, 修复操作〉对。无需人工标注；数据来源于现有故障管理系统。

针对每条查询，由任务可行的最小外部教师模型（本项目以 14B 为参考）温度采样（τ=0.8, top-p=0.95）生成 k 条候选推理链。“任务可行” 意指该模型能以非平凡概率产出正确修复操作；根据子场景难度可动态选择 7B–32B 范围内满足条件的最小模型，相比直接调用 72B 全量 LLM 将生成成本降低约 5×–10×。选择外部教师（而非令目标 SLM 自举）的根本原因在于：冷启动场景下 1.5B/4B 目标模型尚不具备解题能力——若它已具备，该场景就不再是冷启动问题。

对每条候选 CoT，提取末尾预测操作序列 $\hat{a}_j = \text{ans}(c_j)$ 与标准答案 $a = (o_1, \ldots, o_m)$ 进行集合等价匹配（$\equiv$，规范化后）：

$$\mathcal{D}^* = \left\{ (q,\, c_j,\, a) \;\middle|\; \text{ans}(c_j) \equiv a,\; j = 1, \ldots, k \right\}$$

操作序列的结构化性质（每个 o_i 为 `restart_service`、`scale_pod` 等结构化运维指令）保证匹配判断完全自动化，无需任何领域知识。数据质量保障：涉及操作员失误或标签模糊的记录（多次重试后成功、部分修复）通过轻量异常过滤器排除，仅保留” 单次操作后故障在窗口期 T 内无复现” 的高置信样本。保留率通常在 30–70% 区间（k=8），已足够为 Cycle 2 提供高质量训练数据。

Cycle 2——有监督推理训练（SFT + LoRA）。 将 $\mathcal{D}^*$ 中的验证三元组 $\langle q, c^*, a \rangle$ 用于对紧凑型 SLM（简单子任务选用 1.5B，复杂子任务选用 4B）进行带 LoRA 的监督微调，最大化 CoT 与答案的联合自回归似然。损失函数对推理链过短（$|c| < \gamma$）的样本降权，防止模型旁路推理步骤直接输出答案。此阶段产出初始 SLM π_0（AIOps-0），它已能遵循任务格式并输出合理推理链，但化学（或运维）准确率尚未收敛。

Cycle 3——AIOps 聚焦策略优化（AIOps-GRPO）。 仅靠 SFT 无法保证 SLM 推理链导向正确操作——SFT 拟合的是教师采样分布，而非最优推理策略。Cycle 3 对 π_0 施加群体相对策略优化（GRPO [Agarwal et al., 2024]）：每条 prompt 生成 8 条 rollout，按奖励计算组内相对优势，更新策略参数。

AIOps 奖励设计。相比分子科学需要 RDKit 化学验证器，AIOps 的结构化操作格式天然提供等效信号：

- $\mathcal{R}_{\text{format}}$：输出符合结构化操作列表格式；
- $\mathcal{R}_{\text{CoT}}$：推理链长度超过最小阈值（激励实质性推理，而非直接输出答案）；
- $\mathcal{R}_{\text{EM}}$：操作序列与标准答案精确匹配（与 Cycle 1 使用同一验证函数，无需额外实现）；
- $\mathcal{R}_{\text{soft}}$：操作类型匹配但参数有差异时给予部分分，提供稠密学习信号；
- $\mathcal{R}_{\text{len}}$（负项）：对过长推理链的软惩罚，防止推理游荡。

总奖励 $\mathcal{R}_{\text{total}} = \sum_k \lambda_k \mathcal{R}_k$，权重 $\boldsymbol{\lambda}$ 使 $\mathcal{R}_{\text{EM}}$ 和 $\mathcal{R}_{\text{soft}}$ 的联合权重主导（约 0.5），其余项各均分剩余权重。KL 散度惩罚限制策略偏离初始点，保持训练稳定。此阶段产出最终专家 SLM π^*，并封装为 MCP 工具端点注册至 Planner 层。

Bootstrap 回路——自举数据扩充。 当某子任务在 Cycle 1 过滤率为零（$\mathcal{D}^* = \emptyset$）时，STaR 的自蒸馏路径陷入死锁：无训练数据，模型无法改进。MOLE1 的迭代架构天然处理这一情形：用当前已训练的 *SLM*（π_t，而非外部教师）对失败样本重新采样，通过答案验证过滤新的通过样本，将其写回 $\mathcal{D}^*$ 扩充数据集，触发下一轮 Cycle 1 → Cycle 2 → Cycle 3 迭代。这一自举回路使数据集与模型能力协同进化：π_t 比外部教师更了解当前训练分布，其采样对困难样本往往比初始教师具有更高通过率。在新子任务积累足够 Bootstrap 样本前，该子任务请求暂由 Planner LLM 直接处理，维持系统可用性而不产出空训练集。

实验设计与评估方案

数据集。采用以下两类数据结合：(a) 来自阿里巴巴运维日志的内部 AIOps 数据集（已与阿里巴巴 SRE 团队初步确认数据访问意向，数据共享协议正在商定中），预估规模不低于 10,000 条有标注修复操作的故障事件，以 8:1:1 比例切分训练/验证/测试集；(b) 公开可用的 AIOps-2022 基准 [Notaro et al., 2021]（保障可复现性）。实验覆盖三个 AIOps 子场景：数据库层故障、网络分区事件和容器资源耗尽。CoT 候选生成阶段每条查询采样 k=8 条推理链，预期经答案验证过滤后保留约 30–70% 作为有效训练数据。若项目进度允许，将对公开代码审查数据集开展探索性跨域实验（目标 O5）。

对比基线。

- **仅 LLM**：通过 API 调用 72B，无本地 SLM。
- **SLM（无 CoT）**：SLM 仅在 ⟨ 输入, 输出 ⟩ 对上微调，无推理链。
- **SLM + 教师 CoT**：SLM 在由 72B 作为教师生成的 CoT 上微调（需要强能力教师，为 “oracle” 上界）。
- **MOLE1（本方案）**：SLM 在 14B 生成的答案验证 CoT 上微调。

评估指标。修复操作准确率（top-1 命中率）、推理延迟（p50/p99）及单查询计算成本（FLOPs / API token）。统计显著性通过自助重采样（n=1000）评估。

系统架构：Planner + MCP 工具层

图 3 展示了整体部署架构。

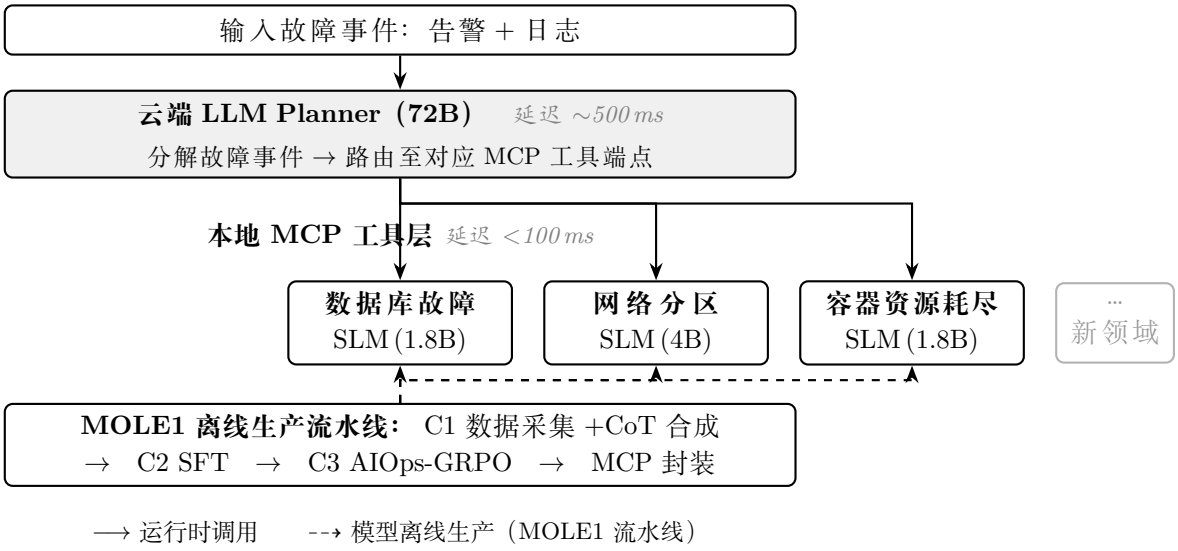

图 3: 系统架构：云端 LLM 作为 Planner，统筹调度由 MOLE1 流水线生产的本地 MCP 端点 SLM。

云端 LLM（72B 或同等模型）充当 **Planner**：它将输入的故障事件分解为子任务，确定执行顺序，并调用相应的 MCP 工具端点。每个 MCP 工具封装一个专为单一 AIOps 子场景训练的 SLM （如数据库慢查询诊断、网络分区检测、容器 OOM 分诊）。

Planner–Executor 分层设计体现了两种角色的非对称性：

- Planner 需要全局语义理解，以分解新颖的多步故障事件——这种能力依赖大模型的广度。
- 每个 Executor 需要深度、窄域专业知识，专注单一子领域——这种能力受益于在领域专属 CoT 数据上的专注训练，不受益于大模型多任务训练所强加的泛化约束。

该设计同时带来延迟优势：仅 Planner 调用经过云端 API（∼500 ms）；所有 Executor SLM 推理均在本地运行（<100 ms），因此即便在高告警量下，端到端系统也能在秒级内响应。

专家 SLM 为何能超越通用 LLM

”专业化优于泛化”现象在蒸馏文献 [Hsieh et al., 2023, Dong et al., 2024] 中已有充分支撑，源于两点观察：(i) 通用 LLM 的参数在数千个任务间共享，稀释了单一领域的表示容量 [Wang et al., 2025]；(ii) 专注于领域 CoT 数据微调的 SLM 占据参数空间中更低维的子空间，与目标领域推理模式高度对齐，在参数量远少的情况下实现更高精度。我们将通过实证证据（消融研究，变量为模型规模与训练数据领域纯度）和容量分配分析，对上述直觉进行形式化论证。

为何不直接用 14B 中型模型作为 Executor？有人会问：既然 14B 已具备 CoT 能力，且可在单张 A100 GPU 上本地运行，为何还要进一步蒸馏到 1.5B/4B 模型？原因有三：(1) 准确率：专注于领域验证 CoT 训练的 1.5B/4B SLM 在目标子任务上优于 14B 通用模型——该

尺度下领域纯度效应主导了规模效应 [Dong et al., 2024]；(2) *部署规模*：在拥有数百台主机的大型平台中，1.5B/4B SLM 可与每个服务节点共同部署，内存开销可忽略，实现零延迟本地推理，无需 GPU 调度；(3) *成本*：1.5B 推理 FLOPs 约为 14B 的 ≈1/9（4B 约为 1/3.5），并支持动态选择——简单子任务使用 1.5B Executor，复杂子任务调用 4B Executor——对于高频故障监控（每分钟数千事件）至关重要。

技术优势

将 MOLE1 与现有 LLM–SLM 协同及 SLM 蒸馏方法对比：

1. **创新性**。现有 LLM–SLM 协同框架（FrugalGPT、RouteLLM）假设专家 SLM 已存在，完全聚焦于路由策略。现有 CoT 蒸馏方法（STaR、Distilling Step-by-Step）需要人工标注 CoT 或具备领域知识的教师模型。MOLE1 首次填补了冷启动空白：*无需人工标注*、*无需领域感知教师*，仅以历史记录中已有的标准答案作为验证器，实现专家 SLM 的自动化生产。这填补了两条研究脉络中的关键盲点。

2. **可部署性**。三循环设计在操作上高度透明：（Cycle 1）收集历史记录、运行教师模型采样、按答案匹配过滤；（Cycle 2）SFT+LoRA 训练初始 SLM；（Cycle 3）以操作匹配为奖励运行 AIOps-GRPO；（Bootstrap）用当前 SLM 扩充数据集并触发下一迭代；最终封装为 MCP 工具端点注册至 Planner 层。任何阿里巴巴 SRE 团队均可在数天内将流水线应用于新 AIOps 子场景，无需人工标注预算，仅需配置奖励权重与数据路径。

3. **有效性**。领域专属 CoT 训练产出的 SLM，在窄领域任务上能与 GPT-4 级 LLM 持平甚至超越，尽管参数量相差数量级——这是蒸馏文献 [Hsieh et al., 2023, Dong et al., 2024] 中的成熟结论，MOLE1 将其推广至冷启动答案验证场景。”专业化优于泛化”现象的实证与理论分析将作为项目成果的一部分输出。

4. **高效性**。MOLE1 标注开销为零，所需算力仅为训练或调用通用 LLM 的一小部分。推理阶段收益立竿见影：本地 SLM 执行（<100 ms）消除了高频 AIOps 监控任务的云端 API 成本与延迟，流水线开销远小于其替代的 LLM API 费用。

5. **通用性**。MOLE1 仅需具有可自动验证答案的历史〈输入, 输出〉对——这一条件在工业界广泛成立（客服工单分流、代码审查分类、供应链异常检测）。设计完成后，可无需领域专属再工程即扩展至阿里巴巴多条业务线，成为广泛可复用的冷启动资产，远超本项目所演示的 AIOps 场景。

讨论：为何选择 MOLE1，而非其他可行方案

以下逐一分析批阅者可能想到的四类替代方案，并说明它们与 MOLE1 的关系或局限。

方案一：仅用 RLVR/GRPO，跳过 Cycle 1 SFT 直接强化学习。将 GRPO 作为*唯一*训练手段（纯自博弈强化学习，无 SFT 初始化）已在数学、编程等任务展示出强大的 CoT 涌现能力。然而，纯 GRPO 有一个硬性前提：策略模型在零/少样本条件下须已具备*正概率*生成正确答案的能力，才能产出任何正奖励 rollout 以驱动学习。在冷启动 AIOps 场景中，1.5B/4B 目标 SLM 对新故障子场景的零样本成功率接近零，纯 GRPO 与 STaR 面临同样的启动死锁。此外，超参数（KL 系数、奖励权重、温度）的敏感性使纯 GRPO 在每次新子场景上频繁调优的工程成本较高。

值得强调的是，MOLE1 *并不放弃* GRPO——Cycle 3 的 AIOps-GRPO 正是在 Cycle 2 SFT

之后施加的策略优化，与原型系统 Logos 分子科学管道的 M-GRPO 阶段同构。Logos 的消融实验表明，GRPO 阶段贡献了最大的精度提升。MOLE1 在 AIOps 中保留了这一设计，但将奖励函数从（需要 RDKit 等领域验证器的）化学合法性信号，替换为操作序列精确匹配（$\mathcal{R}_{\text{EM}}$）与结构化格式信号——两者均无需任何额外工具，直接复用 Cycle 1 的验证函数，显著降低了部署门槛。本方案讨论的是"是否用 GRPO"，而 MOLE1 的答案是肯定的，争议仅在于以何种奖励设计用之。

方案二：RAG + 提示工程。检索增强生成（RAG）通过在推理时检索相关历史案例来提升 LLM 准确率，无需训练，部署快速。然而，RAG 的核心局限在于：它不生产可本地部署的 *SLM*。每次查询仍须调用云端 LLM（延迟 500 ms–2 s），在高频故障监控场景（每分钟数千事件）下既不可承受也不可靠。RAG 可作为 MOLE1 第一阶段（数据采集）的辅助手段，但无法替代本项目的核心目标：产出一个延迟 <100 ms 的本地专家 SLM。

方案三：标准知识蒸馏（输出分布对齐）。标准 KD（MiniLLM [Gu et al., 2024]、DDK [Dong et al., 2024]）通过对齐学生模型与教师模型的输出分布来压缩模型，技术成熟。但其前提是具备领域感知能力的教师模型——教师需能在目标领域生成合理输出，以提供有效的软标签监督信号。冷启动场景下，通用 LLM（如 Qwen3-72B）可以生成输出，但其在领域专属任务上的输出分布本身就是待优化对象：让学生模仿一个尚未专业化的教师，本质上是在用未经验证的知识训练学生。MOLE1 的关键突破在于，以已知标准答案作为外部验证器，仅保留通向正确答案的推理链，从而将通用 LLM 的生成能力转化为经验证的领域特定训练数据，规避了"教师本身不专业"的问题。

方案四：STaR 自蒸馏。STaR [Zelikman et al., 2022] 通过令模型自我采样推理链、按答案正确性过滤、再用过滤后数据微调自身，实现无监督 CoT 涌现，在数学等任务上效果显著。MOLE1 的答案验证过滤机制在形式上与 STaR 的过滤步骤相同，但两者存在一项根本性的前提假设分歧：STaR 要求目标小模型在零样本或少样本条件下以非平凡正概率自解任务，即学生模型本身已能偶尔给出正确答案，才能产出任何通过过滤的样本。而在冷启动 AIOps 场景中，1.5B/4B 目标 SLM 对新引入的子场景（如新型服务网格故障或未见过的微服务交互模式）根本不具备解题能力——若它已具备，该场景就不再是冷启动问题，本课题的研究前提也随之消失。MOLE1 正是针对"学生无法自解"这一严格冷启动条件而设计：引入任务可行的外部最小教师（而非更大的 72B 全量 LLM，后者成本高出约 5×–10×），打破自蒸馏的自引导死锁。此外，如前所述，当过滤率为零时（STaR 的训练数据完全为空），MOLE1 的 Planner 层提供了系统级降级路由，而 STaR 在此处无任何回退机制。

综合结论。上述四类方案各有其适用场景，但均不能在冷启动约束下同时满足：(i) 无标注数据要求、(ii) 产出可本地部署的 SLM、(iii) 不依赖领域感知教师、(iv) 满足工业级延迟要求、(v) 在目标小模型自解能力为零的严格冷启动条件下仍可运行。MOLE1 是在这五项约束下唯一可行的方案，且其完整三循环机制（Cycle 1 答案验证 CoT 合成 + Cycle 2 SFT + Cycle 3 领域聚焦 GRPO + Bootstrap 自举）已在 Logos 分子科学原型 [AI for Science (AI4S) Division @ ACE, 2025] 中得到量化验证：专域训练的 4B 模型在结构准确率上达到 EM = 0.5588（ChEBI-20），超越规模远大于其的通用 LLM（GPT-5 EM = 0.2488）。Logos 消融实验进一步表明，GRPO 阶段（Cycle 3）贡献了最大的精度提升（EM 从 ∼0.20 提升至 ∼0.34），证明了完整迭代训练策略的有效性，且该有效性与具体领域无关。

2. 里程碑计划

2.1 项目周期

一年，自《研究合作协议》生效之日起计。

2.2 计划安排

表 1: 项目里程碑与交付物。

阶段	工作内容	交付物	时间段
M1	**流水线设计与数据准备**。形式化 MOLE1 算法；采集并预处理 AIOps ⟨输入, 输出⟩ 数据集；实现 CoT 候选生成（14B）与答案验证过滤器。	数据集与过滤模块；技术报告。	第 1–3 月
M2	**Cycle 2/3 训练与基准测试**。（Cycle 2）在 $\mathcal{D}^*$ 上 SFT+LoRA 训练得到 π_0；（Cycle 3）施加 AIOps-GRPO，以操作匹配奖励强化推理质量，得到 π^*；与通用 LLM 基线在 AIOps 基准上对比；专业化机制消融分析。	训练好的 π_0 和 π^* 模型；GRPO 奖励消融报告；CCF-A 论文 #1 草稿。	第 4–7 月
M3	**Bootstrap 迭代、系统集成与 MCP 打包**。对失败子任务运行 Bootstrap 回路（π_t 自举 → 写回 $\mathcal{D}^*$ → 再训练）；将各 π^* 封装为 MCP 工具端点；集成 Planner（72B）与 MCP 工具层；端到端延迟与准确率评估。	Bootstrap 迭代实验报告；开源 MCP 工具套件；系统演示；CCF-A 论文 #2 草稿。	第 8–9 月
M4	**评估、专利申请与最终交付**。全系统评估；与阿里巴巴相关方开展用户研究；专利申请；项目结题报告。	结题报告；已发表/投稿论文；专利申请（1–2 项）。	第 10–12 月

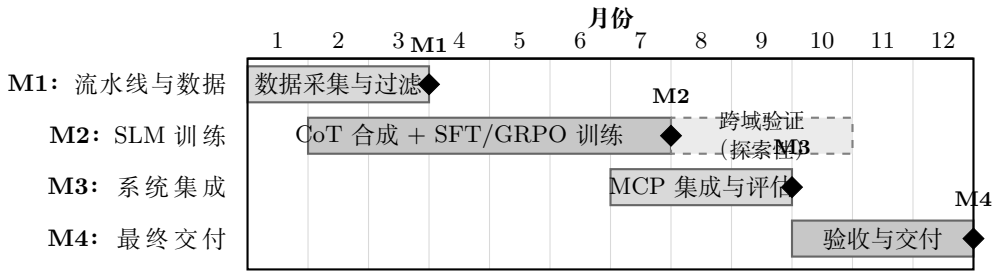

图 4: 项目甘特图（四个里程碑）。

3. 交付成果

本项目承诺如下最终交付成果。

1. **算法原型系统**。完整的 MOLE1 三循环迭代 SLM 生产流水线：（Cycle 1）数据采集模块、CoT 候选生成与答案验证过滤器；（Cycle 2）SFT + LoRA 监督训练模块；（Cycle 3）AIOps-GRPO 策略优化模块（含奖励函数实现）；Bootstrap 自举回路（π_t 对失败样本采样 $\rightarrow$ 过滤 $\rightarrow$ 写回 $\mathcal{D}^*$）；及 MCP 工具端点打包工具。源代码在 GitHub 开源发布；提供完整可复现实验环境。

2. **MCP 合规 AIOps 工具端点套件**。针对 2–3 个 AIOps 子场景（数据库层故障、网络分区事件、容器资源耗尽）打包的 SLM Executor 原型，含 Planner 层集成文档与接入指南。

3. **设计文档**。提交 1 份总体设计文档（系统架构与流水线规格）及 1 份详细设计文档（算法、评估方案与部署指南）。

4. **论文目标**。投稿论文 2 篇至 CCF-A 或同等顶级会议（如 NeurIPS、ICML、ACL、ICSE、FSE），涵盖 MOLE1 方法与 AIOps 评估结果，争取于项目结题前至少 1 篇完成录用。

5. **专利目标**。就冷启动 CoT 合成与 MCP 端点封装提交发明专利申请 1–2 项（国内或国际）。

6. **技术指标**。与现有 AIOps 方案对比：MOLE1 生产的 SLM 修复操作准确率在 GPT-4 级 LLM 的 5% 以内，单次推理延迟降低 $>10\times$（从 $\sim$1 s 降至 $<$100 ms），单查询 token 成本降至零（本地推理）。

7. **业务目标**。系统在 2 个以上 AIOps 子场景完成原型部署与性能验证，并有文档记录相对仅 LLM 基线的延迟与准确率提升。

8. **项目验收报告**。项目结束时提交 1 份最终验收测试报告。

9. **学生联合培养与实习**。联合培养参与本项目的研究生 2–3 名；在项目期间提供赴阿里巴巴 SRE 团队实习机会（预计第 4–9 月，以阿里巴巴排期为准）。

表 2: 交付成果汇总及交付方式。

说明	交付方式	备注
原型系统：MOLE1 冷启动 SLM 生产流水线	源代码（开源）	可复现；在 GitHub 发布
MCP 合规 AIOps 工具端点套件	源代码 + 文档	兼容标准 MCP 协议
总体设计文档与详细设计文档	技术报告	分别于 M1、M3 里程碑提交
MOLE1 方法论与 AIOps 评估学术论文 2 篇	学术论文	目标 CCF-A 或同等顶级会议
冷启动 CoT 合成与 MCP 打包发明专利 1–2 项	专利申请	国内或国际专利
中期与结题项目报告	项目报告	按约定时间表提交
送研究生赴阿里巴巴 SRE 团队实习	人员安排	2–3 名博士生；预计第 4–9 月，完成项目落地验证

4. 人员、设备与经费预算

4.1 人员配置

姓名	背景	月薪（元）	周期	折合全时	合计	角色	实习
王茂林	研究助理教授, 香港城市大学	12,000	3 月	0.25 FTE	36,000	负责人	—
<FILL: PhD 1>	博士生, *<FILL: Univ.>*	12,000	12 月	1.0 FTE	144,000	研究助理	第 4–6 月
<FILL: PhD 2>	博士生, *<FILL: Univ.>*	12,000	12 月	1.0 FTE	144,000	研究助理	第 7–9 月
				人员费用小计（a）			**RMB 324,000**

实习时间段为预估值；具体日期以阿里巴巴 *SRE* 团队排期为准。

4.2 设备与耗材

项目	单价（元）	合计（元）	备注
GPU 云计算（A100 节点时长）	—	91,000	用于 SLM 训练（第二至三阶段）
本地推理服务器（租赁/购买）	50,000	50,000	MCP 端点部署与延迟测试
学术会议差旅（2 场）	15,000	30,000	国内及国际顶级会议参会
开放获取出版费	10,000	20,000	ACL Anthology / NeurIPS 开放获取
	科研经费小计（b）	**191,000**	

4.3 经费预算

项目	备注	金额（元）
（a）人员费用合计	详见第 4.1 节	324,000
（b）科研经费合计	详见第 4.2 节	191,000
（c）间接费用	学校管理费：$16.5\% \times (a+b) = 16.5\% \times 515{,}000 \approx 85{,}000$	85,000
合计	（a）+（b）+（c）	**600,000**

5. 主要研究人员简介

王茂林（Maolin Wang）
研究助理教授，计算机科学系，香港城市大学（City University of Hong Kong）
电子邮件：maolwang2@cityu.edu.hk 个人主页：`https://scholars.cityu.edu.hk/en/persons/maolwang2`

教育背景：

- 博士，数据科学方向，香港城市大学（2021–2025）（导师：赵翔宇教授；共同导师：Ruocheng Guo 博士、王俊晖教授）
- 硕士，计算机科学系，电子科技大学（2018–2021）（导师：徐增林教授）
- 学士，英才实验学院，电子科技大学（2014–2018）

研究方向：大语言模型、知识蒸馏、AIOps 与智能运维、自动机器学习、智能软件系统。

代表性成果（近五年）：

1. **Wang M.** et al. “FLUID-MMRec: Stein-Guided Entropic Flow for Multi-Modal Sequential Recommendation.” *KDD 2025*（CCF-A）。[**第一作者**]
2. **Wang M.** et al. “DANCE: Resource-Efficient Neural Architecture Search with Data-Aware and Continuous Adaptation.” *KDD 2025 & IJCAI 2025*（CCF-A）。[**第一作者**]

3. Peng J., **Wang M.** et al. "Stepwise Reasoning Error Disruption Attack of LLMs." *ACL 2025*（CCF-A）。
4. Liu Z., Liu Q., **Wang M.** et al. "SIGMA: Selective Gated Mamba for Sequential Recommendation." *AAAI 2025*（CCF-A）。
5. Han X., **Wang M.** et al. "Data Efficient Adaptation in Large Language Models via Continuous Low-Rank Fine-Tuning." *NeurIPS 2025*（CCF-A）。

代表性项目与获奖：

- KDD 2025 最佳论文亚军奖（Best Paper Award Runner-Up），ACM SIGKDD，2025 年。
- ACM SIGKDD 学生旅行奖（KDD 2025 Student Travel Award），2025 年。
- 代表性产业落地：模型压缩成果（EI-BERT，1.9 MB）已在支付宝多条业务线上线，成为基础能力。

学术服务：

- 程序委员会委员 / 审稿人：NeurIPS、KDD、WWW、AAAI、IJCAI、ACL、SIGIR、RecSys。

与本申请高度相关的具体经历。

1. *<FILL: 在该方向于 [列举 CCF-A 会议及年份] 发表论文 N 篇，其中 N 篇以第一作者或通讯作者身份发表。代表论文：[1] … [2] …>*
2. *<FILL: 在 [公司] 研究合作/实习期间（[时长]），作为核心成员参与 [项目名称]（基于 LLM 蒸馏/AIOps/AutoML 的系统），主导 [具体模型/组件] 在 [N] 条业务线（[产品名称]）上的部署，取得 [具体量化成果，如"延迟降低 50%"或"故障诊断准确率提升 X%"]。>*
3. *<FILL: 在 CCF-A 会议（[列举会议及年份]）就 [相关主题，如"LLM–SLM 协同"或"自动化 AIOps"] 发表 [教程/特邀报告]，获得 [广泛关注/好评]。就该主题撰写综述论文 [题目，arXiv/会议，年份]。>*

6. 参考文献

6. 参考文献

R. Agarwal, N. Vieillard, P. Stanczyk, S. Ramos, M. Geist, and O. Bachem. On-policy distillation of language models: Learning from self-generated mistakes. In *International Conference on Learning Representations (ICLR)*, 2024.

AI for Science (AI4S) Division @ ACE. Logos: an evolvable reasoning engine for molecular science. arXiv preprint, 2025.

Alibaba Cloud. Qwen3 technical report. Technical report, Alibaba Group, 2025.

J. Dong et al. DDK: Distilling domain knowledge for efficient large language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.

Y. Gu, L. Dong, F. Wei, and M. Huang. MiniLLM: Knowledge distillation of large language models. In *International Conference on Learning Representations (ICLR)*, 2024.

C.-Y. Hsieh, C.-L. Li, C.-K. Yeh, H. Nakhost, Y. Fujii, A. Ratner, R. Krishna, C.-Y. Chen, and T. Pfister. Distilling step-by-step! outperforming larger language models with less training data and smaller model sizes. In *Findings of the Association for Computational Linguistics (ACL)*, 2023.

A. Notaro, J. Cardoso, M. Gerndt, and M. Brenner. Aiops: Real-world challenges and research innovations. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 12(6), 2021.

C.-Y. Wang et al. A survey of small language models. *arXiv preprint arXiv:2410.20011*, 2025.

E. Zelikman, Y. Wu, J. Mu, and N. D. Goodman. STaR: Bootstrapping reasoning with reasoning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.