阿里巴巴 AI 研究资助计划 2026

研究申请书

项目名称	基于大模型冷启动蒸馏的 MCP 端点专家模型自动化生产 ——面向 AIOps 故障应急响应
课题方向	课题一（大小模型协同）/ 课题十（AIOps）
日期	2026 年 3 月
申请机构	香港城市大学 计算机科学系
申请人（负责人）	王茂林（Maolin Wang）
电子邮件	maolwang2@cityu.edu.hk

本申请书响应 *Alibaba AI Research Scheme 2026* 资助计划。
资助金额：人民币 *60* 万元，项目周期：一年。

1. 项目介绍

1.1 项目标题

基于大模型冷启动蒸馏的 MCP 端点专家模型自动化生产——面向 AIOps 故障应急响应

1.2 背景与意义

产业背景。阿里巴巴等大规模互联网平台须保障近乎零停机时间。以电商大促场景为例，单次高峰期可触发数万条告警，人工 triage 每条平均耗时 5–15 分钟，[1] 产生数百工程师-小时的应急成本，且高压情境下人工误判率显著上升。Qwen3 系列模型 [Alibaba Cloud, 2025] 的成熟为该流程的自动化打开了大门，然而云端 LLM API 单次调用延迟高达 500 ms–2 s，在高频故障风暴下极易超时；而本地部署的小语言模型（SLM）响应时延 <100 ms，对延迟敏感的 AIOps 执行层不可或缺。

LLM–SLM 协同中被忽视的前提。课题一要求探索大小模型如何有效协同。现有协同框架（如 FrugalGPT、RouteLLM）隐含假设*专家小模型已经存在*，贡献的是路由或调度策略，却未回答更根本的问题：*专家小模型从何而来？*现有 SLM 生产方法——无论是基于人工标注思维链（CoT）的监督微调 [Hsieh et al., 2023]、基于教师模型输出分布对齐的知识蒸馏 [Gu et al., 2024, Dong et al., 2024]，还是令模型自我采样推理链再过滤的自举方法 [Zelikman et al., 2022]——均依赖以下至少一项：(a) 人工标注 CoT；(b) 具备领域知识的教师模型；(c) 已有非平凡解题能力的学生模型。而在*冷启动场景*——新 AIOps 子场景的常态——上述资源均不可得（图 1）。

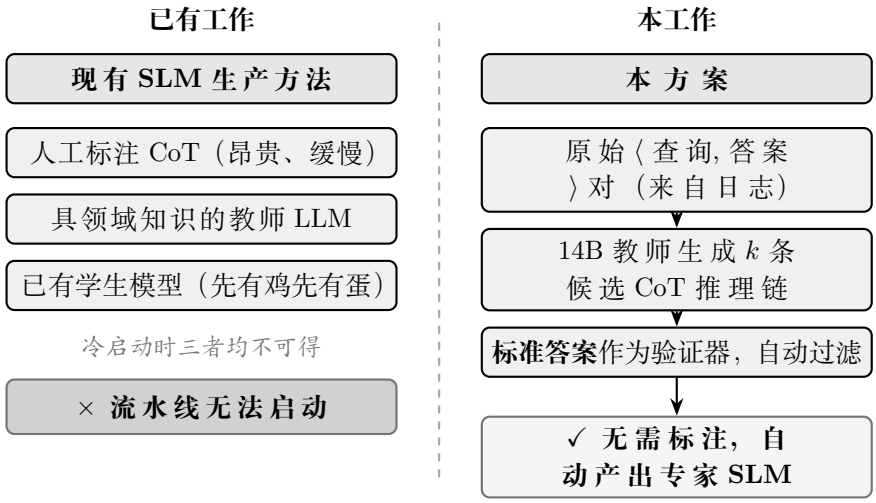

图 1: 现有 SLM 生产方法在冷启动场景下失效（左）；本方案以历史记录中已有的标准答案作为自动验证器，绕过这一瓶颈（右）。

核心问题。如何在*零人工标注、无领域感知教师*的严格冷启动条件下，仅从原始〈输入, 输出〉对自动生产具有推理能力的专家 SLM？现有工作——规则引擎、ML 分类器或检索增强生成（RAG）——均未解决这一问题：规则引擎无法泛化到新故障类型；ML 分类器缺乏可解释推理步骤；RAG 每次仍须调用云端 LLM，未能消除延迟瓶颈。本项目针对这一研究空白，拟设计并验证一套全自动的冷启动 SLM 生产流水线。

为何 AIOps 是理想验证场景。三项结构性特点使 AIOps 成为验证本方案的最佳领域：

[1] 基于阿里巴巴内部大促运维报告估算；类似规模见 Notaro et al. [2021]。

1. **数据天然符合格式需求**。每个平台的运维数据库中均积累了大量 ⟨ 告警 + 日志, 修复操作 ⟩ 对，恰好符合所需的 ⟨ 输入, 输出 ⟩ 格式，无需额外标注工作量。
2. **客观二值验证**。”所提修复方案是否解决了故障？”的真值信号已存于历史记录，可通过故障回放完全自动化评估，无需人工裁判或领域专家介入。
3. **可量化的延迟价值**。本地 SLM 推理时延 <100 ms，相较云端 API 的 500 ms–2 s，直接解决高频告警场景的工业痛点，量化指标清晰可复现。

1.3 研究目标

本项目设定四项紧密关联的研究目标：

O1. 冷启动专家 SLM 生产框架。设计并验证一套三循环迭代流水线，仅从原始 ⟨ 输入, 输出 ⟩ 对出发，经由答案验证 CoT 合成（Cycle 1）、监督推理训练（Cycle 2）、领域聚焦策略优化（Cycle 3）及自举（Bootstrap）回路，实现冷启动条件下专家 SLM 的全自动化生产。

O2. AIOps 场景系统验证。在阿里巴巴运维数据集及公开 AIOps 基准 [Notaro et al., 2021] 上验证所提流水线，证明本地专家 SLM 在故障诊断与修复准确率上能达到或接近通用大模型的水准。

O3. 专业化机制实证分析。通过消融实验（变量为模型规模、训练数据领域纯度、CoT 过滤率）及表示空间分析（t-SNE 可视化、CKA 层间相似度），对”领域专属 CoT 训练使小模型在窄域任务上超越大模型”现象进行实证论证。

O4. 跨域适用性初探（探索性）。在资源允许的条件下，将流水线应用于 AIOps 以外的公开数据集（如代码审查分类），初步验证本方法的领域无关性；若时间有限，此目标以消融实验形式完成并作为后续工作铺垫。

工程交付物（非研究目标）：将训练好的 SLM 封装为 MCP（Model Context Protocol）合规工具端点并集成至 Planner 层，作为 O1 研究成果向生产环境迁移的必要工程出口，不构成独立研究贡献。

量化目标：所产出 SLM 在 AIOps 故障诊断基准上达到 GPT-4 级 LLM 修复准确率的 5% 以内，单次推理延迟降低 >10×（从 ∼1 s 降至 <100 ms），单查询 token 成本降至零（本地推理）。学术产出：投稿论文 2 篇至 CCF-A 或同等顶级会议（如 NeurIPS、ICML、ICSE、FSE），争取于项目结题前至少 1 篇完成录用；就冷启动 CoT 合成与 MCP 端点封装申请发明专利 1–2 项；系统在 2 个以上 AIOps 子场景完成原型部署与性能验证。

1.4 研究方法

核心思路：三循环迭代答案验证 CoT 合成

本项目拟设计一套**三循环迭代 CoT 合成流水线**，领域无关，无需任何人工标注或具备领域知识的教师模型，将原始 ⟨ 输入, 输出 ⟩ 对转化为具有推理能力的专家 SLM。系统由三个相互依存的训练循环构成，并配有一个自举（Bootstrap）回路：

$$
\begin{array}{lll}
\text{Cycle 1:} & \underbrace{\langle q,\, a\rangle}_{\text{冷启动数据}} \xrightarrow{\text{最小教师, } k \text{ 采样 + 答案过滤}} & \underbrace{\mathcal{D}^*}_{\text{验证三元组集}} \\
\text{Cycle 2:} & \mathcal{D}^* \xrightarrow{\text{SFT+LoRA}} & \underbrace{\pi_0}_{\text{初始 SLM}} \\
\text{Cycle 3:} & \pi_0 \xrightarrow{\text{AIOps-GRPO}} & \underbrace{\pi^*}_{\text{专家 SLM}} \\
\text{Bootstrap:} & \pi_t\big(\mathcal{D}_\emptyset\big) \xrightarrow{\text{过滤}} \mathcal{D}^*_{\text{new}} \hookrightarrow \mathcal{D}^* \xrightarrow{\text{触发下一轮 Cycle 1}} & \pi_{t+1}
\end{array}
$$

其中 q = 查询，a = 标准答案，$\mathcal{D}_\emptyset$ = 本轮过滤率为零的失败样本集，π_t = 第 t 轮训练所得 SLM。这一设计的关键在于：以历史记录中已有的标准答案作为唯一外部验证信号，无需引入额外人工监督，即可自动筛选通向正确答案的推理链，从而将通用模型的生成能力转化为经验证的领域特定训练数据。在相邻科学计算领域，类似的迭代答案验证思路已展现出方法论上的可行性 [AI for Science (AI4S) Division @ ACE, 2025]；本项目的目标是系统探索该思路在 AIOps 冷启动场景下的适用条件、奖励信号设计与泛化能力。

三循环训练流程

图 2 展示了完整的三循环流水线。

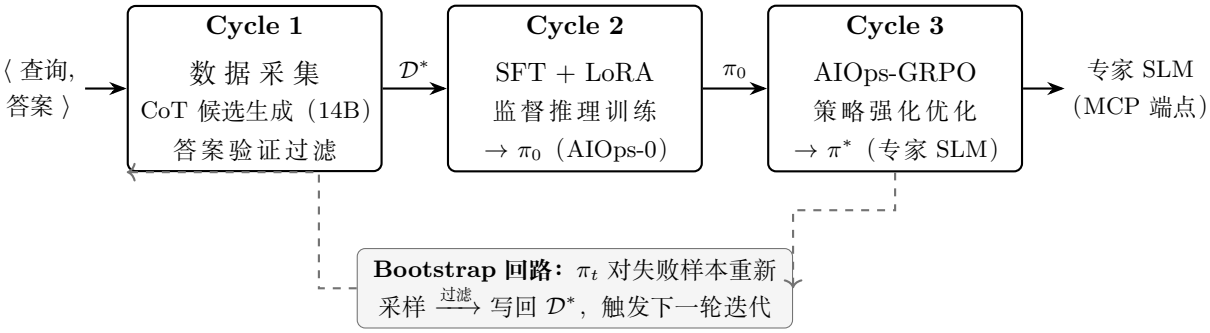

图 2: 三循环迭代流水线：Cycle 1 产出验证数据集，Cycle 2 SFT 得到初始 SLM，Cycle 3 策略优化强化推理质量，Bootstrap 回路驱动数据与模型协同进化。

Cycle 1——数据采集与验证 CoT 合成。 从运维日志中收集〈告警 + 日志，修复操作〉对，无需任何人工标注；数据来源于现有故障管理系统。

针对每条查询，由任务可行的最小外部教师模型（温度采样 τ=0.8，top-p=0.95）生成 k 条候选推理链。”任务可行的最小模型”指在目标子场景能以非平凡概率产出正确答案的最小可用模型；相比直接调用 72B 全量模型，可将生成成本降低约 5×–10×。选择外部教师的根本原因在于：冷启动条件下目标 SLM 尚不具备解题能力，自举路径无法启动。

对每条候选推理链，提取末尾预测操作序列 $\hat{a}_j = \mathrm{ans}(c_j)$ 与标准答案 $a = (o_1, \ldots, o_m)$ 进行集合等价匹配（规范化后）：

$$
\mathcal{D}^* = \big\{\, (q,\, c_j,\, a) \;\big|\; \mathrm{ans}(c_j) \equiv a,\; j = 1, \ldots, k \,\big\}
$$

操作序列的结构化性质（每个 o_i 为 `restart_service`、`scale_pod` 等运维指令）保证匹配判断完全自动化，无需领域知识。涉及操作员失误或标签模糊的记录通过轻量异常过滤器排除；保留率通常在 30–70% 区间（k=8），足以为下一阶段提供高质量训练数据。

Cycle 2——有监督推理训练（SFT + LoRA）。 将 $\mathcal{D}^*$ 中的验证三元组 $\langle q, c^*, a\rangle$ 用于对紧凑型 SLM（简单子任务选用 1.5B，复杂子任务选用 4B）进行带 LoRA 的监督微调，最大化 CoT 与答案的联合自回归似然。损失函数对推理链过短（$|c| < \gamma$）的样本降权，防止模型旁路推理步骤直接输出答案。此阶段产出初始 SLM π_0，它已能遵循任务格式并输出合理推理链，但准确率尚待进一步强化。

Cycle 3——领域聚焦策略优化（AIOps-GRPO）。 仅靠 SFT 无法保证推理链导向正确操作——SFT 拟合的是采样分布，而非最优推理策略。对 π_0 施加群体相对策略优化 [Agarwal et al., 2024]：每条 prompt 生成 8 条 rollout，按奖励计算组内相对优势并更新策略参数。

AIOps 奖励设计。 AIOps 的结构化操作格式天然提供等效于领域验证器的信号：

- $\mathcal{R}_{\text{format}}$：输出符合结构化操作列表格式；
- $\mathcal{R}_{\text{CoT}}$：推理链长度超过最小阈值（激励实质性推理，而非直接输出答案）；
- $\mathcal{R}_{\text{EM}}$：操作序列与标准答案精确匹配（复用 Cycle 1 的验证函数，无需额外实现）；
- $\mathcal{R}_{\text{soft}}$：操作类型匹配但参数有差异时给予部分分；
- $\mathcal{R}_{\text{len}}$（负项）：对过长推理链的软惩罚。

总奖励 $\mathcal{R}_{\text{total}} = \sum_k \lambda_k \mathcal{R}_k$，$\mathcal{R}_{\text{EM}}$ 与 $\mathcal{R}_{\text{soft}}$ 的联合权重主导（约 0.5），KL 散度惩罚限制策略偏离初始点以保持训练稳定。

Bootstrap 回路——自举数据扩充。 当某子任务在 Cycle 1 过滤率为零（$\mathcal{D}^* = \emptyset$）时，训练数据完全为空，流水线陷入死锁。迭代架构天然处理这一情形：用当前已训练的 *SLM*（π_t，而非外部教师）对失败样本重新采样，经答案验证过滤后写回 $\mathcal{D}^*$，触发下一轮迭代，实现数据集与模型能力的协同进化。在积累足够 Bootstrap 样本前，该子任务请求暂由 Planner LLM 直接处理，维持系统可用性而不产出空训练集。

实验设计与评估方案

数据集。采用两类数据结合：(a) 来自阿里巴巴运维日志的内部 AIOps 数据集（已与 SRE 团队初步确认数据访问意向，数据共享协议正在商定中），预估规模不低于 10,000 条故障事件，以 8:1:1 比例切分训练/验证/测试集；(b) 公开可用的 AIOps-2022 基准 [Notaro et al., 2021]（保障可复现性）。实验覆盖三个子场景：数据库层故障、网络分区事件和容器资源耗尽。CoT 候选生成阶段每条查询采样 k=8 条推理链。

对比基线。

- **仅 LLM**：通过 API 调用 72B，无本地 SLM。
- **SLM（无 CoT）**：SLM 仅在 ⟨ 输入, 输出 ⟩ 对上微调，无推理链。
- **SLM + 教师 CoT**：SLM 在由 72B 作为教师生成的 CoT 上微调（oracle 上界）。
- **本方案**：SLM 在答案验证 CoT 上微调，教师仅为任务可行的最小模型。

评估指标。修复操作准确率（top-1 命中率）、推理延迟（p50/p99）及单查询计算成本（FLOPs

/ API token）。统计显著性通过自助重采样（n=1000）评估。

系统架构：Planner + MCP 工具层

图 3 展示了整体部署架构。

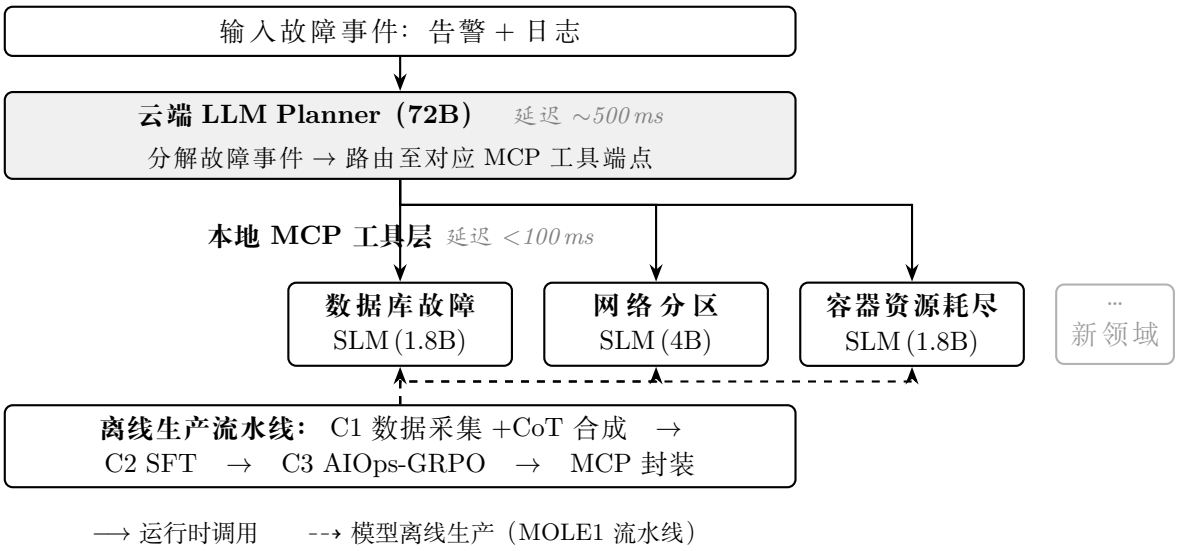

图 3: 系统架构：云端 LLM 作为 Planner，统筹调度由三循环流水线离线生产的本地 MCP 端点 SLM。

云端 LLM（72B 或同等模型）充当 **Planner**：它将输入的故障事件分解为子任务，确定执行顺序，并调用相应的 MCP 工具端点。每个 MCP 工具封装一个专为单一 AIOps 子场景训练的 SLM （如数据库慢查询诊断、网络分区检测、容器 OOM 分诊）。

Planner–Executor 分层设计体现了两种角色的非对称性：Planner 需要全局语义理解以分解新颖的多步故障事件——依赖大模型的广度；每个 Executor 需要深度、窄域专业知识——受益于领域专属 CoT 数据的专注训练，而非大模型多任务训练所强加的泛化约束。延迟优势同样显著：仅 Planner 调用云端 API（∼500 ms）；所有 Executor 推理均在本地运行（<100 ms），端到端系统可在秒级内响应高频告警。

领域专属 CoT 训练使 SLM 在窄域任务上与规模远大于其的通用大模型竞争，这一现象在蒸馏文献中已有充分记录 [Hsieh et al., 2023, Dong et al., 2024]：专注训练使参数占据更低维的领域特异子空间，在参数量远少的情况下实现更高的任务准确率。此外，1.5B/4B SLM 可与服务节点共同部署，内存开销极低，支持简单子任务使用 1.5B、复杂子任务使用 4B 的动态选择策略，对高频故障监控（每分钟数千事件）至关重要。本项目将通过消融实验与表示空间分析对上述机制进行系统验证。

2. 里程碑计划

2.1 项目周期

一年，自《研究合作协议》生效之日起计。

2.2 计划安排

表 1: 项目里程碑与交付物。

阶段	工作内容	交付物	时间段
M1	**流水线设计与数据准备**。形式化三循环迭代算法；采集并预处理 AIOps ⟨ 输入, 输出 ⟩ 数据集；实现 CoT 候选生成与答案验证过滤器。	数据集与过滤模块；技术报告。	第 1–3 月
M2	**Cycle 2/3 训练与基准测试**。（Cycle 2）在 $\mathcal{D}^*$ 上 SFT+LoRA 训练得到 π_0；（Cycle 3）施加 AIOps-GRPO 强化推理质量，得到 π^*；与通用 LLM 基线对比；专业化机制消融分析。	训练好的 π_0 和 π^* 模型；消融实验报告；CCF-A 论文 #1 草稿。	第 4–7 月
M3	**Bootstrap 迭代、系统集成与 MCP 打包**。对失败子任务运行 Bootstrap 回路；将各 π^* 封装为 MCP 工具端点；集成 Planner 与 MCP 工具层；端到端延迟与准确率评估。	Bootstrap 实验报告；开源 MCP 工具套件；系统演示；CCF-A 论文 #2 草稿。	第 8–9 月
M4	**评估、专利申请与最终交付**。全系统评估；与阿里巴巴相关方开展用户研究；专利申请；项目结题报告。	结题报告；已发表/投稿论文；专利申请（1–2 项）。	第 10–12 月

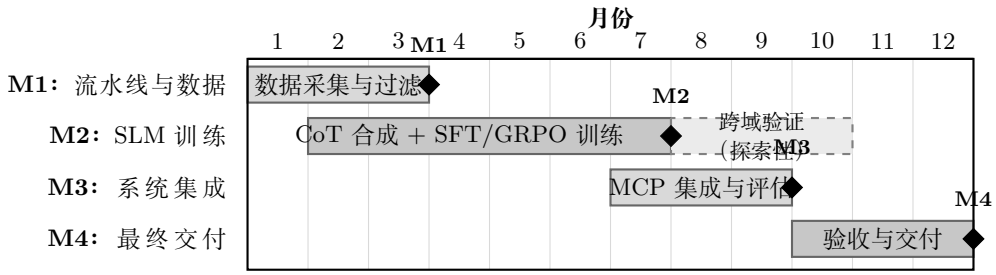

图 4: 项目甘特图（四个里程碑）。

3. 交付成果

本项目承诺如下最终交付成果。

1. **算法原型系统**。完整的三循环迭代 SLM 生产流水线：数据采集模块、CoT 候选生成与答

案验证过滤器（Cycle 1）；SFT + LoRA 监督训练模块（Cycle 2）；AIOps-GRPO 策略优化模块，含奖励函数实现（Cycle 3）；Bootstrap 自举回路；及 MCP 工具端点打包工具。源代码在 GitHub 开源发布；提供完整可复现实验环境。

2. **MCP 合规 AIOps 工具端点套件**。针对 2–3 个 AIOps 子场景（数据库层故障、网络分区事件、容器资源耗尽）打包的 SLM Executor 原型，含 Planner 层集成文档与接入指南。

3. **设计文档**。提交 1 份总体设计文档（系统架构与流水线规格）及 1 份详细设计文档（算法、评估方案与部署指南），分别于 M1、M3 里程碑交付。

4. **论文目标**。投稿论文 2 篇至 CCF-A 或同等顶级会议（如 NeurIPS、ICML、ACL、ICSE、FSE），涵盖所提方法与 AIOps 评估结果，争取于项目结题前至少 1 篇完成录用。

5. **专利目标**。就冷启动 CoT 合成与 MCP 端点封装提交发明专利申请 1–2 项（国内或国际）。

6. **技术指标**。所产出 SLM 修复操作准确率在 GPT-4 级 LLM 的 5% 以内，单次推理延迟降低 >10×（从 ∼1 s 降至 <100 ms），单查询 token 成本降至零（本地推理）。

7. **业务目标**。系统在 2 个以上 AIOps 子场景完成原型部署与性能验证，并有文档记录相对仅 LLM 基线的延迟与准确率提升。

8. **项目验收报告**。项目结束时提交 1 份最终验收测试报告。

9. **学生联合培养与实习**。联合培养参与本项目的研究生 2–3 名；在项目期间提供赴阿里巴巴 SRE 团队实习机会（预计第 4–9 月，以阿里巴巴排期为准）。

表 2: 交付成果汇总及交付方式。

说明	交付方式	备注
原型系统：三循环迭代冷启动 SLM 生产流水线	源代码（开源）	可复现；在 GitHub 发布
MCP 合规 AIOps 工具端点套件	源代码 + 文档	兼容标准 MCP 协议
总体设计文档与详细设计文档	技术报告	分别于 M1、M3 里程碑提交
所提方法与 AIOps 评估学术论文 2 篇	学术论文	目标 CCF-A 或同等顶级会议
冷启动 CoT 合成与 MCP 打包发明专利 1–2 项	专利申请	国内或国际专利
中期与结题项目报告	项目报告	按约定时间表提交
送研究生赴阿里巴巴 SRE 团队实习	人员安排	2–3 名博士生；预计第 4–9 月，完成项目落地验证

4. 人员、设备与经费预算

4.1 人员配置

姓名	背景	月薪（元）	周期	折合全时	合计	角色	实习
王茂林	研究助理教授，香港城市大学	12,000	3 月	0.25 FTE	36,000	负责人	—
<FILL: PhD 1>	博士生，*<FILL: Univ.>*	12,000	12 月	1.0 FTE	144,000	研究助理	第 4–6 月
<FILL: PhD 2>	博士生，*<FILL: Univ.>*	12,000	12 月	1.0 FTE	144,000	研究助理	第 7–9 月
				人员费用小计（a）			**RMB 324,000**

实习时间段为预估值；具体日期以阿里巴巴 *SRE* 团队排期为准。

4.2 设备与耗材

项目	单价（元）	合计（元）	备注
GPU 云计算（A100 节点时长）	—	91,000	用于 SLM 训练（第二至三阶段）
本地推理服务器（租赁/购买）	50,000	50,000	MCP 端点部署与延迟测试
学术会议差旅（2 场）	15,000	30,000	国内及国际顶级会议参会
开放获取出版费	10,000	20,000	ACL Anthology / NeurIPS 开放获取
	科研经费小计（b）	**191,000**	

4.3 经费预算

项目	备注	金额（元）
（a）人员费用合计	详见第 4.1 节	324,000
（b）科研经费合计	详见第 4.2 节	191,000
（c）间接费用	学校管理费：$16.5\% \times (a+b) = 16.5\% \times 515{,}000 \approx 85{,}000$	85,000
合计	（a）+（b）+（c）	**600,000**

5. 主要研究人员简介

王茂林（Maolin Wang）
研究助理教授，计算机科学系，香港城市大学（City University of Hong Kong）

电子邮件：maolwang2@cityu.edu.hk 个人主页：`https://scholars.cityu.edu.hk/en/persons/maolwang2`

教育背景：

- 博士，数据科学方向，香港城市大学（2021–2025）（导师：赵翔宇教授；共同导师：Ruocheng Guo 博士、王俊晖教授）
- 硕士，计算机科学系，电子科技大学（2018–2021）（导师：徐增林教授）
- 学士，英才实验学院，电子科技大学（2014–2018）

研究方向：大语言模型、知识蒸馏、AIOps 与智能运维、自动机器学习、智能软件系统。

代表性成果（近五年）：

1. **Wang M.** et al. "FLUID-MMRec: Stein-Guided Entropic Flow for Multi-Modal Sequential Recommendation." *KDD 2025*（CCF-A）。[**第一作者**]
2. **Wang M.** et al. "DANCE: Resource-Efficient Neural Architecture Search with Data-Aware and Continuous Adaptation." *KDD 2025 & IJCAI 2025*（CCF-A）。[**第一作者**]
3. Peng J., **Wang M.** et al. "Stepwise Reasoning Error Disruption Attack of LLMs." *ACL 2025*（CCF-A）。
4. Liu Z., Liu Q., **Wang M.** et al. "SIGMA: Selective Gated Mamba for Sequential Recommendation." *AAAI 2025*（CCF-A）。
5. Han X., **Wang M.** et al. "Data Efficient Adaptation in Large Language Models via Continuous Low-Rank Fine-Tuning." *NeurIPS 2025*（CCF-A）。

代表性项目与获奖：

- KDD 2025 最佳论文亚军奖（Best Paper Award Runner-Up），ACM SIGKDD，2025 年。
- ACM SIGKDD 学生旅行奖（KDD 2025 Student Travel Award），2025 年。
- 代表性产业落地：模型压缩成果（EI-BERT，1.9 MB）已在支付宝多条业务线上线，成为基础能力。

学术服务：

- 程序委员会委员 / 审稿人：NeurIPS、KDD、WWW、AAAI、IJCAI、ACL、SIGIR、RecSys。

与本申请高度相关的具体经历。

1. *<FILL: 在该方向于 [列举 CCF-A 会议及年份] 发表论文 N 篇，其中 N 篇以第一作者或通讯作者身份发表。代表论文：[1] … [2] …>*
2. *<FILL: 在 [公司] 研究合作/实习期间（[时长]），作为核心成员参与 [项目名称]，主导 [具体模型/组件] 在 [N] 条业务线（[产品名称]）上的部署，取得 [具体量化成果，如"延迟降低 50%"或"故障诊断准确率提升 X%"]。>*
3. *<FILL: 在 CCF-A 会议（[列举会议及年份]）就 [相关主题，如"LLM–SLM 协同"或"自动化 AIOps"] 发表 [教程/特邀报告]。就该主题撰写综述论文 [题目，arXiv/会议，年份]。>*

6. 参考文献

6. 参考文献

R. Agarwal, N. Vieillard, P. Stanczyk, S. Ramos, M. Geist, and O. Bachem. On-policy distillation of language models: Learning from self-generated mistakes. In *International Conference on Learning Representations (ICLR)*, 2024.

AI for Science (AI4S) Division @ ACE. Logos: an evolvable reasoning engine for molecular science. arXiv preprint, 2025.

Alibaba Cloud. Qwen3 technical report. Technical report, Alibaba Group, 2025.

J. Dong et al. DDK: Distilling domain knowledge for efficient large language models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.

Y. Gu, L. Dong, F. Wei, and M. Huang. MiniLLM: Knowledge distillation of large language models. In *International Conference on Learning Representations (ICLR)*, 2024.

C.-Y. Hsieh, C.-L. Li, C.-K. Yeh, H. Nakhost, Y. Fujii, A. Ratner, R. Krishna, C.-Y. Chen, and T. Pfister. Distilling step-by-step! outperforming larger language models with less training data and smaller model sizes. In *Findings of the Association for Computational Linguistics (ACL)*, 2023.

A. Notaro, J. Cardoso, M. Gerndt, and M. Brenner. Aiops: Real-world challenges and research innovations. *ACM Transactions on Intelligent Systems and Technology (TIST)*, 12(6), 2021.

E. Zelikman, Y. Wu, J. Mu, and N. D. Goodman. STaR: Bootstrapping reasoning with reasoning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.